

Satisfiable but Wrong: Solver-Decidable Abstention for LLM Constraint Formalization

(引言与相关工作重写稿)

Anonymous submission

引言

自然语言约束推理要求系统从题面恢复变量、关系与全局约束，再交由形式求解器生成答案。Logic-LM [1]、LINC [2] 与 SatLM [3] 分别将 LLM 与逻辑程序、一阶逻辑证明器和可满足性求解器结合，这一范式随后扩展到答案集编程 [4]、约束建模 [7, 8] 与优化建模 [9]。在基于可满足性求解的流水线中，系统通常将求解器返回 SAT 作为接受答案的依据 [1, 3]。

这一接受规则存在明确盲区：SAT 只说明生成约束彼此一致，不说明它们忠实表达了题意。当线索被遗漏或弱化时，约束集仍然可满足，而求解器给出的答案在任务层面是错误的；本文称这类失败为可满足但错误 (satisfiable-but-wrong, SBW)。该盲区并非本文杜撰，而是被该方向的奠基工作反复点名却未解决：Logic-LM 明确承认“合法的符号表示不必然等于正确的问题形式化” [1]；其后续改进指出，由于修正环节“没有任何证明层面的检查”，语法正确但语义错误的公式会被迭代修复直接接受 [5]；SatLM 在附录中记录了求解器正常返回、答案却错误的案例类别 [3]；在唯一解逻辑谜题上，LLM 生成的答案集程序同样出现“能运行但解错”的语义错误，补救手段是人工检查 [4]。SATBench 进一步表明，线索遗漏后欠约束的形式化仍会稳定返回 SAT [10]。

现有三类应对均不覆盖这一失败模式。其一，修复流程的触发条件是显式故障——语法错误、执行失败或 UNSAT；自反馈复审在推理任务上并不稳定 [14, 16]，而以不可满足核为线索的诊断与修复 [18, 19, 20] 恰好构成 SBW 的对偶——社区为“过约束导致冲突”建立了成熟的工具链，为“欠约束保持可满足”没有留下任何触发器。其二，语义对齐路线直接比较题面与形式表示，包括学习式对齐评分 [24]、候选间符号等价 [25, 26]、回译一致性 [27] 与经形式验证过滤的多次采样投票 [28]；这些方法要么依赖额外模型与文本比较，要么需要多倍采样，且信号是启发式或半可判定的——即便将等价检查确定化，其召回率也仅约一半 [29]。其三，选择性预测为“何时拒答”提供了标准框架 [31, 33, 34]，但面向 LLM 的拒答信号大多读取自评置信度 [35] 或多次采样一致性 [37, 38]：前者被系统性证明过度自信 [35]，后者只度量输出分布的离散度，对“多次采样一致地遗漏同一条线索”原理上失明。

本文因此研究一个更窄、但由求解器可判定的问题：当任务规范本身给出答案空间的结构条件时，能否在 SAT 之后、不读取任何金标答案值的前提下，把该条件用作选择性作答的拒答依据？在唯一答案任务中，该条

件即答案变量投影 $\text{Sol}_A(C)$ 恰含一个元素。系统只需一次增量阻塞子句查询——禁止已得的答案投影并重解——即可判定是否存在第二个不同的答案投影，而无需枚举全部模型；确定非唯一即结构性拒答，确定唯一则放行，预算内无法判定的 UNKNOWN 与“结构通过”被明确分开。

该信号的理论边界是单侧的，本文将其作为立论前提而非事后限定：若真实答案唯一，且错误仅来自未排除真实答案的纯欠约束（遗漏或弱化线索），则答案投影必然非唯一，唯一性门控必然检出；反之，“唯一但错”的形式化会通过门控。因此该信号是形式化质量的可判定必要条件检查，不是语义正确性证明，也不定位遗漏了哪条线索。诚实地说，构成该门控的每个部件都有先例：阻塞子句与增量求解是求解器社区的标准原语 [41, 42]，“求一解后禁解重查”在数学应用题的病题检测中已被逐字使用 [11]，SatLM 也已将求解器端的多解与不可满足信号用于选择性作答 [3]。本文的贡献不在发明机制，而在把散落的实现细节提炼为一个有理论刻画、有明确语义边界、可系统评测的一等接口。

本文的主要贡献如下：

- **命名并界定 SBW 的可诊断边界。**在唯一答案、纯欠约束的前提下，答案投影必然非唯一，故可被唯一性门控检出；唯一但错的 SAT 输出会逃逸门控。该单侧保证同时给出方法的能与不能。
- **提出 SPARC: SAT 后结构门控的一等接口。**在一般答案变量集合 V_A 上构造投影阻塞子句，以单次增量查询实现无需训练、不读取金标答案值、由求解器判定的三值输出（结构通过 / 结构性拒答 / UNKNOWN）。
- **量化检出范围与覆盖率代价。**在冻结的 ZebraLogic [54] SAT 状态上报告 SBW 检出率与正确输出误拒率，并在风险-覆盖率坐标系下与置信度、多次形式化一致性等启发式拒答基线受控比较。

相关工作

LLM 约束形式化与“SAT 即接受”

自动形式化 [23] 催生了让 LLM 只负责翻译、由求解器负责推理的神经符号路线：Logic-LM [1] 生成逻辑程序并以求解器报错驱动自我修正，LINC [2] 生成一阶逻辑交给证明器并以多次采样投票稀释翻译噪声，SatLM [3] 以声明式提示生成可满足性约束；该范式进一步覆盖答案集编程 [4]、SMT [6]、约束建模 [7, 8] 与优化建模 [9]。这些系统的共同接受规则是：求解器一旦成功返回，答

案即被采纳；其忠实性声明均以“形式化正确”为未验证前提 [1]。

与本文最近的三项工作需要逐一划界。**SatLM** [3] 已将求解器端异常用于选择性作答：其错误分类含 UNSAT 与多可行解导致的 AMBIG，遇到两者即拒答并报告选择性准确率。但该歧义检查是面向单个标量答案变量的实现细节（其 AR-LSAT 路径改用逐选项蕴含检查，机制不同），论文未将唯一性上升为任务规范给出的结构谓词，未定义一般 V_A 上的投影阻塞查询，未区分 UNKNOWN 与结构通过，也未给出欠约束与非唯一之间的理论联系。**VCSearch** [11] 在数学应用题上逐字实现了同一求解器机制——求一解、将其作为约束加入、仍可满足即判多解并拒绝——但其目标是检测病题（题面本身缺条件或矛盾），采用多轮 LLM 参与的迭代搜索，不涉及“好题的坏形式化”，也没有选择性预测评测。**SSV** [12] 同样在不读金标的前提下用求解器验证信号换取高选择性精度，但其信号是 LLM 生成具体实例后的可满足性检验，每题需多次模型调用，验证失败先修复重试；本文的唯一性门控只需一次增量求解器查询，且两类信号正交、可以叠加。此外，近期工作把答案集数量写入训练奖励以惩罚欠约束的程序 [13]，但该信号服务于迭代修复而非拒答。本文相对上述工作的定位是：把“答案投影唯一性”提炼为任务规范给出的一等结构谓词，配以单侧保证的理论刻画与系统的风险-覆盖率评测。

形式化的验证、修复与语义对齐

修复路线的触发条件决定了它们的覆盖范围。自反馈复审依赖模型自评 [14, 15]，受控研究表明其在推理任务上并不可靠 [16, 17]；求解器驱动的修复以显式失败为入口——语法错误与执行异常触发 Logic-LM 式自我修正 [1, 5]，UNSAT 与不可满足核触发约束定位与松弛 [18, 19, 20, 21]。触发条件的普查结论是：没有任何一条修复路线以“SAT 但答案投影非唯一”为触发器；不可满足核谱系诊断过约束极为成熟，欠约束侧则没有对应工具。软件规格研究给出了同构的观察：空洞的后置条件（如恒真式）能通过全部正确性检查，必须另测其判别力 [22]——太弱的规格对一切都满足，正如欠约束的形式化保持 SAT。

语义对齐路线绕过求解器状态，直接评估题面与形式表示的一致性，按资源需求可分为：学习式对齐评分需要额外训练的打分模型 [24]；候选间符号等价需要 k 个候选与两两定理证明 [25]，或在翻译期用求解器在候选公式间择优 [26]；回译一致性需要反向翻译模型与文本蕴含判断 [27]，且遗漏的约束在回译文本中往往不可见；经形式验证过滤的自一致投票需要 k 倍采样，且验证的是形式化解的内部一致性而非唯一性 [28]；自生成测试的执行共识则受验证器与被验证对象同源之困 [30]。这些信号或是启发式分数，或是“找到证明才可靠”的半可判定判据——即便将等价检查做成确定性的，召回率也只有约一半，因为自然语言与形式表示的语义等价本质上不可判定 [29]。本文刻意不检查语义等价，只检查任务规范蕴含的可判定结构条件，换取的是单次求解器查询即可得出的确定结论；代价是“唯一但错”超出其检测范围——该情形恰是语义对齐方法的适用域，两条路线互补而非替代。

选择性预测与求解器可判定的拒答信号

不确定时拒答的框架始于 Chow [31]，经选择性分类的风险-覆盖率理论形式化 [32, 33]，并被引入 QA 的分布外场景 [34]。面向 LLM 的拒答信号可按证据强度排成谱系：读取自评置信度的方法被系统性证明过度自信 [35]，拒答能力也可训练内化但不提供实例级证据 [36]；采样一致性 [37] 与语义熵 [38] 度量输出分布的离散度，对“一致地错”结构性失明；共形预测把启发式分数包装为分布层面的边际保证 [39]，但保证属于分布而非单个实例。近期综述的分类学显示，由外部求解器证书提供的确定性拒答信号在现有谱系中几乎缺位 [40]——已知的占位者正是 SatLM 的 UNSAT/AMBIG 拒答 [3]，本文将其从附带的异常处理提升为有理论刻画的机制。

本文借用的求解器原语均是标准件：阻塞子句枚举出自符号模型检测 [41]，增量接口使二次查询近乎免费 [42]，投影变量上的阻塞子句已有成熟实现 [43]。唯一性检验亦有正统血统：“给定一解找另一解”被形式化为 ASP 完全问题，动机正是谜题唯一解检验 [44]，其复杂度定位（唯一可满足性是 coNP 难的 [45]）解释了本文只做“证伪唯一性”的廉价方向、并以 UNKNOWN 承接预算耗尽的设计；程序化谜题生成流水线长期以第二解查询门控生成的谜题实例 [46]——区别在于其被门控对象是约束可信的谜题，本文门控的是约束本身不可信的 LLM 形式化。值得强调的是，必须在答案变量上投影而非比较全模型：辅助变量的可互换取值会造成与答案无关的多解 [47]。概念上更早的先祖是模型检测中的空洞性检测——规约通过验证、但通过方式暴露了规约本身有病 [48]；本文把同型的“通过即怀疑”检查移到答案投影上。

最后，约束获取与程序合成揭示了本文机制的另一半来路。交互式约束获取以可信用户回答成员查询而收敛 [49, 50]，反例引导的综合以完整规格或输入输出 oracle 裁决候选 [51, 52, 53]；其中区分性输入查询——问求解器“是否存在两个都满足当前约束、行为却不同的对象”——与本文的阻塞子句查询在机制上同源 [52]。分叉点在于裁决：这些方法找到区分性对象后可以询问可信 oracle 从而继续收敛，而 LLM 形式化场景中不存在任何可用的 oracle 接口——题面即规格且无法编译为判定器，用户按设定不具备形式化能力，LLM 自生成的检查约束与被检对象同源 [30]。因此本文只继承机制的查询一半：检测结构性欠约束即拒答，不声称获取缺失的约束；LLM 生成候选约束收缩解空间仅是探索性补全，不构成经验证的修复。

参考文献

- [1] Pan, L.; Albalak, A.; Wang, X.; and Wang, W. Y. 2023. Logic-LM: Empowering Large Language Models with Symbolic Solvers for Faithful Logical Reasoning. In *Findings of EMNLP 2023*, 3806–3824.
- [2] Olausson, T. X.; Gu, A.; Lipkin, B.; Zhang, C.; Solar-Lezama, A.; Tenenbaum, J. B.; and Levy, R. 2023. LINC: A Neurosymbolic Approach for Logical Reasoning by Combining Language Models with First-Order Logic Provers. In *Proc. EMNLP 2023*, 5153–5176.

- [3] Ye, X.; Chen, Q.; Dillig, I.; and Durrett, G. 2023. SatLM: Satisfiability-Aided Language Models Using Declarative Prompting. In *Proc. NeurIPS 2023*, vol. 36.
- [4] Ishay, A.; Yang, Z.; and Lee, J. 2023. Leveraging Large Language Models to Generate Answer Set Programs. In *Proc. KR 2023*.
- [5] Kirtania, S.; Gupta, P.; and Radhakrishna, A. 2024. LOGIC-LM++: Multi-Step Refinement for Symbolic Formulations. In *Proc. 2nd Workshop on Natural Language Reasoning and Structured Explanations (NLRSE@ACL 2024)*, 56–63.
- [6] Oh, H.; Stern, S.; Lee, Y.; and Philipose, M. 2026. Neurosymbolic Language Reasoning as Satisfiability Modulo Theory. arXiv:2602.18095.
- [7] Tsouros, D.; Verhaeghe, H.; Kadioglu, S.; and Guns, T. 2023. Holy Grail 2.0: From Natural Language to Constraint Models. arXiv:2308.01589.
- [8] Michailidis, K.; Tsouros, D.; and Guns, T. 2024. Constraint Modelling with LLMs Using In-Context Learning. In *Proc. CP 2024*, LIPIcs vol. 307, 20:1–20:27.
- [9] AhmadiTeshnizi, A.; Gao, W.; and Udell, M. 2024. OptiMUS: Scalable Optimization Modeling with (M)LP Solvers and Large Language Models. In *Proc. ICML 2024*, PMLR 235, 577–596.
- [10] Wei, A.; Wu, Y.; Wan, Y.; Suresh, T.; Tan, H.; Zhou, Z.; Koyejo, S.; Wang, K.; and Aiken, A. 2025. SATBench: Benchmarking LLMs’ Logical Reasoning via Automated Puzzle Generation from SAT Formulas. In *Proc. EMNLP 2025*, 33832–33849.
- [11] Tian, S.-Y.; Zhou, Z.; Yu, K.-Y.; et al. 2025. Bridging the Gap Between Well-Defined and Ill-Defined Problems in Mathematical Reasoning. In *Proc. EMNLP 2025*, 12710–12731.
- [12] Raza, M.; and Milic-Frayling, N. 2025. Instantiation-based Formalization of Logical Reasoning Tasks using Language Models and Logical Solvers. In *Proc. IJCAI 2025*.
- [13] Schrader, T. P.; Lange, L.; Kaminski, T.; Razniewski, S.; and Friedrich, A. 2026. A Solver-in-the-Loop Framework for Improving LLMs on Answer Set Programming for Logic Puzzle Solving. In *Proc. AAAI 2026*.
- [14] Madaan, A.; Tandon, N.; Gupta, P.; et al. 2023. Self-Refine: Iterative Refinement with Self-Feedback. In *Proc. NeurIPS 2023*, vol. 36.
- [15] Shinn, N.; Cassano, F.; Labash, B.; Gopinath, A.; and Narasimhan, K. 2023. Reflexion: Language Agents with Verbal Reinforcement Learning. In *Proc. NeurIPS 2023*, vol. 36.
- [16] Huang, J.; Chen, X.; Mishra, S.; Zheng, H. S.; Yu, A. W.; Song, X.; and Zhou, D. 2024. Large Language Models Cannot Self-Correct Reasoning Yet. In *Proc. ICLR 2024*.
- [17] Olausson, T. X.; Inala, J. P.; Wang, C.; Gao, J.; and Solar-Lezama, A. 2024. Is Self-Repair a Silver Bullet for Code Generation? In *Proc. ICLR 2024*.
- [18] Liffiton, M. H.; and Sakallah, K. A. 2008. Algorithms for Computing Minimal Unsatisfiable Subsets of Constraints. *J. Automated Reasoning* 40(1):1–33.
- [19] Chen, H.; Constante-Flores, G. E.; and Li, C. 2024. Diagnosing Infeasible Optimization Problems Using Large Language Models. *INFOR: Information Systems and Operational Research* 62(4).
- [20] Singh, V.; Cassel, D.; Weir, N.; Feng, N.; and Bayless, S. 2026. VERGE: Formal Refinement and Guidance Engine for Verifiable LLM Reasoning. arXiv:2601.20055.
- [21] Ao, R.; Simchi-Levi, D.; and Wang, X. 2026. OptiRepair: Closed-Loop Diagnosis and Repair of Supply Chain Optimization Models with LLM Agents. arXiv:2602.19439.
- [22] Endres, M.; Fakhoury, S.; Chakraborty, S.; and Lahiri, S. K. 2024. Can Large Language Models Transform Natural Language Intent into Formal Method Postconditions? *Proc. ACM Softw. Eng.* 1(FSE).
- [23] Wu, Y.; Jiang, A. Q.; Li, W.; Rabe, M. N.; Staats, C.; Jamnik, M.; and Szegedy, C. 2022. Autoformalization with Large Language Models. In *Proc. NeurIPS 2022*, vol. 35.
- [24] Lu, J.; Wan, Y.; Huang, Y.; Xiong, J.; Liu, Z.; and Guo, Z. 2025. FormalAlign: Automated Alignment Evaluation for Autoformalization. In *Proc. ICLR 2025*.
- [25] Li, Z.; Wu, Y.; Li, Z.; Wei, X.; Zhang, X.; Yang, F.; and Ma, X. 2024. Autoformalize Mathematical Statements by Symbolic Equivalence and Semantic Consistency. In *Proc. NeurIPS 2024*.
- [26] Ryu, H.; Kim, G.; Lee, H. S.; and Yang, E. 2025. Divide and Translate: Compositional First-Order Logic Translation and Verification for Complex Logical Reasoning. In *Proc. ICLR 2025*.
- [27] Ying, H.; Wu, Z.; Geng, Y.; Yuan, Z.; Lin, D.; and Chen, K. 2024. Lean Workbook: A Large-Scale Lean Problem Set Formalized from Natural Language Math Problems. In *Proc. NeurIPS 2024 Datasets and Benchmarks Track*.
- [28] Zhou, J. P.; Staats, C.; Li, W.; Szegedy, C.; Weinberger, K. Q.; and Wu, Y. 2024. Don’t Trust: Verify — Grounding LLM Quantitative Reasoning with Autoformalization. In *Proc. ICLR 2024*.
- [29] Poiroux, A.; Weiss, G.; Kunčak, V.; and Bosse-lut, A. 2025. Reliable Evaluation and Benchmarks for Statement Autoformalization. In *Proc. EMNLP 2025*.
- [30] Chen, B.; Zhang, F.; Nguyen, A.; Zan, D.; Lin, Z.; Lou, J.-G.; and Chen, W. 2023. CodeT: Code Generation with Generated Tests. In *Proc. ICLR 2023*.

- [31] Chow, C. K. 1957. An Optimum Character Recognition System Using Decision Functions. *IRE Trans. Electronic Computers* EC-6(4): 247–254.
- [32] El-Yaniv, R.; and Wiener, Y. 2010. On the Foundations of Noise-free Selective Classification. *J. Machine Learning Research* 11:1605–1641.
- [33] Geifman, Y.; and El-Yaniv, R. 2017. Selective Classification for Deep Neural Networks. In *Proc. NeurIPS 2017*, vol. 30.
- [34] Kamath, A.; Jia, R.; and Liang, P. 2020. Selective Question Answering under Domain Shift. In *Proc. ACL 2020*, 5684–5696.
- [35] Xiong, M.; Hu, Z.; Lu, X.; Li, Y.; Fu, J.; He, J.; and Hooi, B. 2024. Can LLMs Express Their Uncertainty? An Empirical Evaluation of Confidence Elicitation in LLMs. In *Proc. ICLR 2024*.
- [36] Zhang, H.; Diao, S.; Lin, Y.; Fung, Y. R.; Lian, Q.; Wang, X.; Chen, Y.; Ji, H.; and Zhang, T. 2024. R-Tuning: Instructing Large Language Models to Say ‘I Don’t Know’. In *Proc. NAACL 2024*.
- [37] Wang, X.; Wei, J.; Schuurmans, D.; Le, Q.; Chi, E.; Narang, S.; Chowdhery, A.; and Zhou, D. 2023. Self-Consistency Improves Chain of Thought Reasoning in Language Models. In *Proc. ICLR 2023*.
- [38] Farquhar, S.; Kossen, J.; Kuhn, L.; and Gal, Y. 2024. Detecting Hallucinations in Large Language Models Using Semantic Entropy. *Nature* 630:625–630.
- [39] Quach, V.; Fisch, A.; Schuster, T.; Yala, A.; Sohn, J. H.; Jaakkola, T. S.; and Barzilay, R. 2024. Conformal Language Modeling. In *Proc. ICLR 2024*.
- [40] Wen, B.; Yao, J.; Feng, S.; Xu, C.; Tsvetkov, Y.; Howe, B.; and Wang, L. L. 2025. Know Your Limits: A Survey of Abstention in Large Language Models. *Trans. ACL* 13:529–556.
- [41] McMillan, K. L. 2002. Applying SAT Methods in Unbounded Symbolic Model Checking. In *Proc. CAV 2002*, LNCS vol. 2404, 250–264. Springer.
- [42] Eén, N.; and Sörensson, N. 2004. An Extensible SAT-solver. In *SAT 2003 Selected Revised Papers*, LNCS vol. 2919, 502–518. Springer.
- [43] Gebser, M.; Kaufmann, B.; and Schaub, T. 2009. Solution Enumeration for Projected Boolean Search Problems. In *Proc. CPAIOR 2009*, LNCS vol. 5547, 71–86. Springer.
- [44] Yato, T.; and Seta, T. 2003. Complexity and Completeness of Finding Another Solution and Its Application to Puzzles. *IEICE Trans. Fundamentals* E86-A(5):1052–1060.
- [45] Valiant, L. G.; and Vazirani, V. V. 1986. NP is as Easy as Detecting Unique Solutions. *Theoretical Computer Science* 47:85–93.
- [46] De Kegel, B.; and Haahr, M. 2020. Procedural Puzzle Generation: A Survey. *IEEE Trans. Games* 12(1):21–40.
- [47] Freuder, E. C. 1991. Eliminating Interchangeable Values in Constraint Satisfaction Problems. In *Proc. AAAI 1991*, 227–233.
- [48] Kupferman, O.; and Vardi, M. Y. 2003. Vacuity Detection in Temporal Model Checking. *Int. J. Software Tools for Technology Transfer* 4(2):224–233.
- [49] Bessiere, C.; Coletta, R.; Hebrard, E.; Katsirelos, G.; Lazaar, N.; Narodytska, N.; Quimper, C.-G.; and Walsh, T. 2013. Constraint Acquisition via Partial Queries. In *Proc. IJCAI 2013*.
- [50] Tsouros, D.; Berden, S.; and Guns, T. 2024. Learning to Learn in Interactive Constraint Acquisition. In *Proc. AAAI 2024*, 8154–8162.
- [51] Solar-Lezama, A.; Tancau, L.; Bodik, R.; Seshia, S.; and Saraswat, V. 2006. Combinatorial Sketching for Finite Programs. In *Proc. ASPLOS 2006*, 404–415.
- [52] Jha, S.; Gulwani, S.; Seshia, S. A.; and Tiwari, A. 2010. Oracle-Guided Component-Based Program Synthesis. In *Proc. ICSE 2010*, 215–224.
- [53] Jha, S.; and Seshia, S. A. 2017. A Theory of Formal Synthesis via Inductive Learning. *Acta Informatica* 54(7):693–726.
- [54] Lin, B. Y.; Le Bras, R.; Richardson, K.; Sabharwal, A.; Poovendran, R.; Clark, P.; and Choi, Y. 2025. ZebraLogic: On the Scaling Limits of LLMs for Logical Reasoning. In *Proc. ICML 2025*, PMLR 267, 37889–37905.
- [55] Zhong, W.; Wang, S.; Tang, D.; Xu, Z.; Guo, D.; Chen, Y.; Wang, J.; Yin, J.; Zhou, M.; and Duan, N. 2022. Analytical Reasoning of Text. In *Findings of NAACL 2022*, 2306–2319.